

강화학습기반 불완전 조영 좌심방이 전자동 지역화 및 분할 기법

김소정^{0,1}, 윤종업¹, 전병환^{1,*}

¹한국의국어대학교 컴퓨터공학부

sojeong22@hufs.ac.kr, juyoon@hufs.ac.kr, bhjeon@hufs.ac.kr

*교신저자

요 약

심방세동(Atrial Fibrillation, AF)은 뇌졸중 등 심각한 합병증의 주요 원인 중 하나이며 좌심방이(Left Atrial Appendage, LAA)는 혈전 형성의 주요 위험 부위로 알려져 있다. 본 연구는 좌심방이 말단의 복잡한 구조로 인해 발생하는 불완전 조영의 문제를 해결하며 좌심방이의 형태를 정밀히 분석하고 형태 분류 및 분석에 기여할 수 있는 전자동 지역화 및 분할 기법을 제안한다. 먼저 2D U-Net 을 활용한 초기 바이너리 마스크를 얻은 후에 EDT(Euclidean Distance Transform) map 을 기반으로 강화학습을 적용하여 LAA neck 의 중심점을 탐지한다. 탐지된 위치를 기반으로 ROI 를 자동으로 설정한다. 이후 3D U-Net 을 결합하여 좌심방이의 구조적 연속성을 고려한 정교한 분할을 수행함으로써 불완전 조영의 문제를 효과적으로 해결하고 결과를 통합 및 보정하여 정확성을 높였다.

1. 서론

심방세동(Atrial Fibrillation, AF)은 전 세계적으로 가장 흔히 발생하는 부정맥 중 하나로, 환자에게 심각한 합병증을 유발할 수 있는 질환이다[1]. 특히 심인성 혈전으로 인한 뇌졸중은 심방세동의 가장 치명적인 결과로 간주된다[2]. 심방세동 환자의 경우, 좌심방이(Left Atrial Appendage, 좌심방이)에서 혈전이 형성될 위험이 높으며, 이는 뇌졸중의 주요 원인이 된다. 좌심방이는 좁고 복잡한 구조와 근육 용기로 이루어진 내벽 때문에 혈전이 잘 형성되는 부위로 알려져 있으며 심장 혈전의 약 90%가 이곳에서 발생하는 것으로 보고된다[3].

정상적인 상태에서 좌심방이는 활발한 혈류를 통해 혈전 생성을 억제하지만 심방세동이나 좌심방수축력 저하와 같은 병리적 상태에서는 혈류 정체로 인해 혈전 형성이 촉진된다[4]. 이는 뇌졸중을 포함한 심각한 합병증을 초래할 수 있으므로 이를 예방하기 위해 좌심방이의 형태학적 구조를 정확히 분석하는 것은 필수적이다[5]. 하지만 구조적 복잡성으로 인해 좌심방이 영역에 조영제가 충분히 도달하지 못하는 한계가 생긴다. 불완전 조영 영역은 정확한 라벨링에 한계를 초래하며 기존의 region growing 기법 또는 threshold 기반 접근 방식으로는 정확하게 분리되지 않는다. 이러한 task 에 기존 접근 방식은 형태 분석 및 진단 과정에서 오류를 증가시킬 수 있다. 또한 2D 기반으로 슬라이스 간 독립적으로 추론하는 경우, 좌심방이의 복잡한 구조적 연속성을 반영하지 못해 정확한 분할이 더욱 어려워지는 한계가 있다.

따라서 본 연구는 3D CT 영상을 기반으로 좌심방이의 형태학적 구조를 분석하기 위한 분할 기법의 활용 가능성을 제시한다. 특히 강화학습을 활용하여 좌심방이의 중심 부위를 정교하게 지역화한 뒤, 3D 패치 기반 분할 기법을 적용하여 복잡한 구조뿐만 아니라 불완전한 조영 영역까지도 정확히 분할할 수 있는 방법을 제안한다.

2. 제안 방법

본 연구에서는 그림 1 과 같이 좌심방이의 해부학적 특성과 심방세동 환자의 혈전 형성 위험을 고려하여 좌심방이를 효과적으로 분할하기 위한 새로운 분할 방법을 제안한다. 먼저 2D U-Net 을 활용하여 초기 분할을 수행한 후, 강화학습을 기반하여 형태학적 특성을 고려한 탐지 및 추출 과정을 자동화한다. 최종적으로 3D U-Net 을 결합하여 정교한 분할이 가능한 전자동 접근 방식을 제안한다.

2.1 2D U-Net 을 활용한 초기 분할

2D U-Net 을 활용하여 좌심방과 좌심방이 영역을 분할하였다[6]. 각 슬라이스를 독립적으로 처리하여 초기 분할 결과로 사용되는 마스크를 생성하였으며, 그림 2 는 이러한 초기 분할 결과를 보여준다.

그림 2 의 왼쪽 이미지는 Ground-Truth 로 좌심방과 좌심방이 영역이 바이너리 마스크 형태로 표현되어 있다. 좌심방은 구조적으로 단순하여 비교적 높은 정확도로 분할되었다.

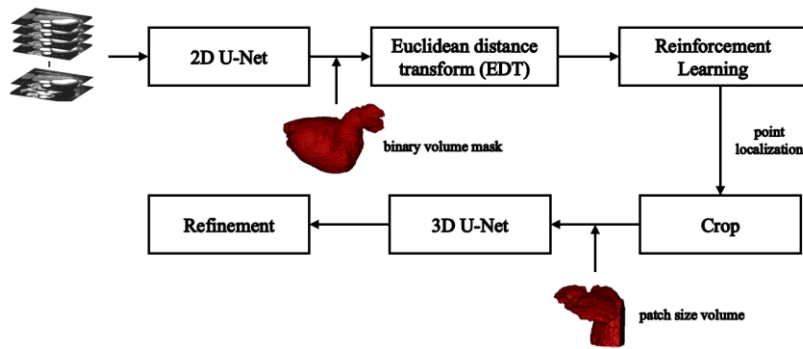


그림 1. 제안된 방법의 전체 프로세스

그림 2의 오른쪽 이미지는 2D U-Net 모델을 기반으로 추론한 결과이다. 여기서 강조되어 확대된 영역을 보면 좌심방이는 복잡한 형태적 특성과 조영제가 충분히 도달하지 못하는 영역이 존재함을 보여준다. 이러한 불완전 조영은 분할 정확도가 낮은 한계가 나타났다. 특히, 이러한 불완전 조영 영역은 region growing 기법이나 threshold 기반 접근 방식으로도 효과적으로 탐지되지 않아 라벨링 과정에서 누락될 가능성이 존재한다. 이러한 한계를 보완하기 위해 먼저 강화학습 기반의 정교한 좌심방이 중심점 지역화와 3D 문맥 정보를 활용하여 정교한 분할 방식을 제안한다.




그림 2. 2D U-Net의 한계

2.2 강화학습 기반 지역화

좌심방이 neck의 중심점 좌표를 정확히 탐지하기 위해 EDT(Euclidean Distance Transform) map과 Reinforcement Learning(RL)을 활용하고자 한다. 좌심방 내부의 HU 값은 균일하여 에이전트가 주변 문맥에서 행동에 필요한 단서를 얻기 어렵기 때문에 학습이 잘 이뤄지지 않는 한계가 있다. 이러한 문제를 해결하기 위해 EDT map을 사용하면 에이전트가 자신의 위치를 식별할 수 있으므로 좌심방이 위치로 순차적으로 찾아갈 수 있는 가이드 맵 역할을 수행할 수 있다. 이렇게 EDT map은 RL의 학습 과정에서 에이전트가 효율적으로 좌심방이 neck의 중심점 위치를 탐색할 수 있도록 돕는 역할을 한다. RL을 통해 탐지된 좌표는 좌심방이 neck의 중심점이며 이후 단계에서 해당 좌표를 기반으로 좌심방이를 충분히 포함하는 영역을 crop 하는데 활용한다.

2.2.1 EDT Map 생성 과정

EDT map은 좌심방과 좌심방이 영역의 바이너리 마스크를 입력으로 받아 각 픽셀이 경계로부터 얼마나 떨어져 있는지를 계산하는 방식으로 이뤄진다. 거리 계산을 통해 생성된 EDT map은 에이전트가 neck 중심점 위치를 탐색하는 동안 목표 지점으로서의 경로를 안내하는 중요한 정보를 제공한다. EDT map을 기반으로 RL 학습 환경이 구성되며 이를 통해 에이전트는 효과적으로 목표 지점을 탐색할 수 있다.

2.2.2 강화학습 기반 좌심방이 중심점 탐지

EDT map을 환경으로 설정하고 에이전트가 seed point에서 시작하여 목표 지점을 탐색한다. seed point는 바이너리 마스크에서 값이 1인 관심 영역의 좌표들의 평균값으로 계산된다. 이렇게 초기 위치를 자동화함으로써 모든 데이터셋을 일반화시켰다. 학습 과정에서 에이전트는 목표 위치인 좌심방이 neck의 중심점에 가까워질수록 더 높은 보상을 받도록 보상 함수가 설계된다[7]. 그림 5-(a)에서 가시화한 것과 같이 에이전트는 점진적으로 최적의 경로를 학습한다. 학습이 완료되면 좌심방이 neck의 중심점 위치를 탐지할 수 있게 된다. 탐지된 위치를 중심으로 방향 벡터를 설정하고, 이 벡터를 기준으로 원뿔 형태의 탐색 공간을 정의하여 좌심방이 영역을 더 정확히 식별할 수 있다.

2.3 3D U-Net 및 Refinement 과정

분할 결과의 정확도를 높이기 위해 3D U-Net 기반 결과와 초기 마스크의 통합 및 후처리 과정을 포함한 Refinement 단계이다. 3D U-Net 모델은 2D U-Net 모델이 가지는 슬라이스 간 연속성을 고려하지 않는 문제를 해결할 뿐만 아니라, 조영제가 끝까지 도달하지 못한 영역에서도 구조적 특성을 보완하여 좌심방이 말단의 복잡한 부위를 정밀히 분할하는데 활용된다[8]. 특히 ROI 탐지 및 추출 과정은 좌심방이의 분할 정확도를 높이기 위한 핵심 단계로 더욱

세밀하고 정교한 분할을 할 수 있다. 최종적으로 CCA(Connected Component Analysis)를 통해 불필요한 영역을 제거하고 결과를 보정하였다.

2.3.1 관심 영역(ROI) 추출

그림 3은 관심 영역(ROI) 추출 과정에서의 주요 단계를 시각적으로 나타낸다. 관심 영역의 평균 좌표인 seed point(파란색 점)에서 RL 단계의 에이전트가 탐지한 좌심방이 neck의 중심점(초록색 점) 방향으로 벡터를 생성하였다. 이 방향 벡터는 탐색 공간을 설정하는데 활용되며 방향 벡터를 따라 주어진 각도 범위 내에서 탐색이 이뤄진다.

탐색 공간은 그림 3 좌측에서 볼 수 있듯이 방향 벡터가 가리키는 방향을 중심으로 원뿔 형태의 search space를 형성하여 해당 범위 내에서 가장 멀리 위치한 점(빨간색 점)을 찾는다.

그림 3 오른쪽 위에서 보이듯이 좌심방이 neck의 중심점 좌표(초록색 점)와 가장 멀리 있는 점(빨간색 점) 사이의 거리를 나타낸다. 이후 계산된 거리에 30만큼의 offset을 더하여 최종 거리 d 를 설정하였다. 탐지된 LAA neck의 중심점 좌표를 (x_0, y_0, z_0) , search space 내에서 가장 멀리 있는 점의 좌표를 (x_1, y_1, z_1) 이라고 할 때, 수식은 다음과 같다.

$$d = \sqrt{(x_0 - x_1)^2 + (y_0 - y_1)^2 + (z_0 - z_1)^2} + offset$$

설정된 d 값을 기준으로, 그림 3 오른쪽 아래에서 볼 수 있듯이 $d/2$ 를 중심으로 하는 정육면체 형태의 ROI를 생성하였다. 결과적으로 생성된 ROI는 $d \times d \times d$ 의 크기를 가지며 좌심방이 영역의 분할을 위한 입력 데이터로 활용된다.




그림 3. 제안된 관심영역 추출 방법

2.3.2 3D U-Net을 활용한 관심영역(ROI) 분할

관심 영역(ROI)이 설정된 이후, 이를 분할하기 위해 3차원 볼륨 데이터를 처리할 수 있는 3D U-Net을 적용하였다. 설정된 ROI는 3D U-Net 모델의 입력 데이터로 사용되며 좌심방이의 구조적 연속성을 고려한 정교한 분할을 수행한다. 단면 간의 구조적

정보를 보존하면서도 좌심방이 영역의 불완전 조영 문제를 해결하고 정확한 형태 분석을 가능하게 하는데 기여한다.

2.3.3 3D 지역 패치 기반 LAA 분할 및 노이즈 제거

두 모델의 결과를 결합하여 각각의 장점을 극대화하였다. 2D U-Net은 좌심방의 넓은 영역을 빠르게 추론하며, 3D U-Net은 좌심방이 영역의 누락된 부분을 보완한다. 두 모델의 상호 보완적인 특성을 활용한 결과의 통합은 복잡한 구조를 가진 좌심방이를 더 정확히 분할할 수 있는 기반을 제공하였다.

통합된 결과를 더욱 정제하기 위해 연결 성분 분석(Connected Component Analysis, CCA)을 적용하였다. CCA는 분할된 영역 내에서 독립적으로 떨어진 구성 요소를 탐지하여 이를 제거함으로써 좌심방이 영역 이외의 불필요한 분할 결과를 제거한다[9].




그림 4. 3D U-Net 예측 및 CCA

그림 4는 3D U-Net 결과 및 CCA 적용 과정을 시각적으로 보여준다. 가장 왼쪽의 이미지는 Ground-Truth로 정답을 나타낸다. 가운데 이미지는 3D U-Net의 prediction 결과로 좌심방이 영역의 복잡한 구조를 잘 반영하였지만 불필요한 작은 영역들이 포함되어 있음을 알 수 있다. 그림에서 화살표로 표시된 부분이 이러한 불필요한 구성 요소를 나타낸다. 이러한 과정을 통해 그림 5-(b)와 같이 더욱 정교한 분할 결과를 얻을 수 있다.




그림 5. (a): 강화학습 에이전트 이동경로 및 탐지, (b): 제안된 방법의 결과 및 CT 볼륨 가시화

3. 실험 결과 및 분석

제안된 방법의 성능은 Dice Similarity Coefficient (DSC)를 사용하여 평가되었다. DSC는 분할된 좌심

방이 영역과 Ground-Truth 간의 겹침 비율을 나타내는 정량적 지표로 값이 높을수록 분할의 정확도가 높음을 의미한다.

3.1 실험 결과

본 연구에서 사용된 데이터는 훈련 데이터와 테스트 데이터를 포함하여 총 36 개의 CT 영상을 사용하였으며, 해당 CT 와 동일한 크기의 정답 볼륨 데이터를 사용했다. 제안된 방법에서는 27 개의 훈련 데이터 셋과 9 개의 테스트 데이터셋으로 나누어 진행하였으며, 평가지표로는 앞서 언급한 DSC 를 사용하여 정량적인 평가를 진행했다. 2 차원 단면만을 독립적으로 분할한 2D U-Net 모델의 결과를 포함하여, 우리가 제안한 방법의 성능을 표 1 에 나타냈다. 슬라이스 간의 연속성을 고려하지 못한 2D U-Net 모델은 평균 78.65%의 성능을 보였으나, 3 차원 구조를 모두 고려하고 불필요한 영역을 제거한 제안된 방법은 84.37%의 성능을 달성할 수 있었다. 특히, 불완전 조영 영역이 있는 좌심방이의 경우 2 차원만을 고려한 모델보다 제안된 3 차원 구조를 고려한 방법이 더욱 뛰어난 성능을 보였다. 훈련 데이터 및 테스트 데이터에는 각각 4 개의 불완전 조영 영역이 있는 좌심방이 데이터가 포함되어 있으며, 불완전 조영 좌심방이에 대한 실험 결과를 통해 2 차원만을 고려한 분할 결과와 3 차원 구조를 고려한 분할 결과를 그림 6 에 제시했다. 제안된 방법은 불완전 조영 좌심방이에 대해 높은 강건성을 보여주며, 3 차원 정보를 활용한 분할이 불완전 조영 영역이 있는 좌심방이에서 보다 정확한 결과를 도출할 수 있음을 확인할 수 있었다.

Dataset	DSC (%)	
	2D U-Net	Proposed method
Data1	79.04	84.88
Data2	82.02	85.72
Data3	76.57	77.24
Data4	72.05	82.33
Data5	78.94	90.34
Data6	85.06	88.28
Data7	82.37	86.09
Data8	78.26	80.36
Data9	73.61	84.13
Avg	78.65±4.18	84.37±3.98

표 1




그림 6. 불완전 조영 좌심방이 실험 결과

4. 결론

해당 연구에서는 3D CT 영상에서 2D U-Net 과 3D U-Net 은 각기 다른 관점에서 영상 분할 작업을 수행하며 서로 보완적인 특성을 가지고 있음을 보였다. 2D U-Net 은 상대적으로 부피가 크고 단순한 구조적 특성을 가진 좌심방 영역은 잘 분할하였다. 좌심방이 영역에서는 구조적 특성이 복잡하고 불완전 조영으로 인해 누락된 부분이 발생하였으며, 슬라이스 간의 연속성을 고려하지 못하는 한계가 발생하였다. 반면, 3D U-Net 은 3 차원 구조를 기반으로 슬라이스 간의 상관관계를 반영하여 좌심방이 영역을 더 정밀히 분할할 수 있는 장점을 가진다. 특히, 이 과정을 통해 불완전 조영으로 인해 정확한 라벨링을 하지 못한다는 한계를 극복할 수 있었다. 이후, CCA 는 통합된 결과를 더욱 정제하여 좌심방이 영역의 불필요한 영역을 제거하고 최종적으로 더 정교한 분할 결과를 도출했다. 향후 연구에서는 분할된 좌심방이 영역을 통해 형태학적 구조를 분류 및 분석할 예정이다.

감사의 글

This work was supported by Hankuk University of Foreign Studies Research Fund of 2025

참고문헌

- [1] Wang, Y. A. N., et al. "Left atrial appendage studied by computed tomography to help planning for appendage closure device placement." *Journal of cardiovascular electrophysiology* 21.9 (2010): 973-982.
- [2] Nattel, Stanley. "New ideas about atrial fibrillation 50 years on." *Nature* 415.6868 (2002): 219-226.
- [3] Al-Saady, N. M., O. A. Obel, and A. J. Camm. "Left atrial appendage: structure, function, and role in thromboembolism." *Heart* 82.5 (1999): 547-554.
- [4] Beigel, Roy, et al. "The left atrial appendage: anatomy, function, and noninvasive

- evaluation." *JACC: Cardiovascular imaging* 7.12 (2014): 1251-1265.
- [5] Healey, Jeff S., et al. "Left Atrial Appendage Occlusion Study (좌심방이 OS): results of a randomized controlled pilot study of left atrial appendage occlusion during coronary bypass surgery in patients at risk for stroke." *American heart journal* 150.2 (2005): 288-293.
- [6] Ronneberger, Olaf, Philipp Fischer, and Thomas Brox. "U-net: Convolutional networks for biomedical image segmentation." *Medical image computing and computer-assisted intervention—MICCAI 2015: 18th international conference, Munich, Germany, October 5-9, 2015, proceedings, part III* 18. Springer International Publishing, 2015.
- [7] Wang, Ziyu, et al. "Dueling network architectures for deep reinforcement learning." *International conference on machine learning*. PMLR, 2016.
- [8] Çiçek, Özgün, et al. "3D U-Net: learning dense volumetric segmentation from sparse annotation." *Medical Image Computing and Computer-Assisted Intervention—MICCAI 2016: 19th International Conference, Athens, Greece, October 17-21, 2016, Proceedings, Part II* 19. Springer International Publishing, 2016.
- [9] He, Lifeng, et al. "Fast connected-component labeling." *Pattern recognition* 42.9 (2009): 1977-1987.